

Représentation des données avec les packages graphics et ggplot2 de **R**

M. L. Delignette-Muller
VetAgro Sup - LBBE

14 décembre 2022



Package graphics

Commençons par tenter de maîtriser le package `graphics` qui est le package graphique de base de **R** ?

Jeu de données exemple

Résultats d'une enquête réalisée sur un échantillon d'étudiants vétérinaires

```
d <- read.table("DATA/ENQ9697.txt", header = TRUE,  
               stringsAsFactors = TRUE)  
str(d)
```

```
'data.frame':      107 obs. of  7 variables:  
 $ SEXE      : Factor w/ 2 levels "F","M": 1 2 1 2 1 1 2 1 1 1 ...  
 $ AGE       : int   22 21 19 20 19 21 21 19 20 22 ...  
 $ POIDS     : int   53 67 63 60 48 58 77 61 52 70 ...  
 $ TAILLE    : int   175 175 172 175 167 171 187 170 161 168 ...  
 $ CADRE     : Factor w/ 2 levels "C","V": 2 1 2 2 2 1 1 1 1 1 ...  
 $ DECISION  : Factor w/ 3 levels "A","E","T": 2 1 1 1 1 2 1 1 2 2 ...  
 $ FILIERE   : Factor w/ 7 levels "A","C","E","I",...: 6 6 3 2 6 1 2 1 6 6
```


La fonction `plot()` du package `graphics`

Une fonction qui permet de réaliser de nombreuses représentations graphiques.

Le graphe qu'elle propose dépend du ou des objets donnés en arguments de la fonction.

plot(varqual) : diagramme en bâtons

```
plot(d$SEXE)
```




Écriture équivalente :

```
barplot(table(d$SEXE))
```

plot(varquant) : séquence des valeurs


plot(d\$AGE)



Tracé des valeurs observées en fonction du numéro de ligne.

`plot(varquant, varquant)` : nuage de points

```
plot(POIDS ~ AGE, data = d)
```




Écriture équivalente :

```
plot(d$AGE, d$POIDS)
```

plot(varqual, varquant) : diagrammes en boîtes

```
plot(POIDS ~ SEXE, data = d)
```



Ecritures équivalentes :

```
plot(d$SEXE, d$POIDS)
```

```
boxplot(POIDS ~ SEXE, data = d)
```



Représentation des variables qualitatives - travail préliminaire souvent nécessaire

```
levels(d$DECISION)
[1] "A" "E" "T"

## Changement du nom des modalités ##
#####
levels(d$DECISION) <-
  c("10-15 ans", "av. 10 ans", "ap. 15 ans")
## Changement de l'ordre des modalités ##
#####
d$DECISION <- factor(d$DECISION,
  levels = c("av. 10 ans", "10-15 ans", "ap. 15 ans"))
```

plot(varqual,varqual) : diagrammes en bandes

```
plot(DECISION ~ SEXE, data = d)
```




Autres fonctions du package graphics

Dans chacun des cas présentés, il existe des alternatives à la réalisation du graphe proposé par défaut par la fonction `plot()`. Pour cela il suffit de faire appel à d'autres fonctions graphiques dont nous allons présenter les plus classiques.


pie(table(varqual)) : diagramme en secteurs

```
pie(table(d$DECISION))
```



hist(varquant) : histogramme de fréquences


```
hist(d$POIDS)
```



`plot(density(varquant))` : estimateur de la densité

```
plot(density(d$POIDS))
```


density.default(x = d\$POIDS)



N = 107 Bandwidth = 3.429

```
plot(density(varquant))  
ajout des valeurs avec rug()
```


```
plot(density(d$POIDS))  
rug(d$POIDS)
```



N = 107 Bandwidth = 3.429

Principe de l'estimateur à noyau de la densité de probabilité illustré sur un sous-échantillon de 8 poids


Mélange de 8 distributions normales centrées sur les 8 observations et de même écart type ajustable (ici 5.32)



N = 8 Bandwidth = 1.874


`plot(ecdf(varquant))` :
diagramme des fréquences cumulées

```
plot(ecdf(d$POIDS), xlab = "âge", ylab = "F")
```



boxplot(varquant) : diagramme en boîte


```
boxplot(d$POIDS)
```



qqnorm(varquant) : diagramme Quantile - Quantile


Quantiles observés en fonction de ceux d'une loi normale pour vérifier la normalité de la distribution (points alignés)

`qqnorm(d$POIDS)`




stripchart(varquant) : visualisation de tous les points

```
stripchart(d$POIDS, method = "stack", pch = 19, at = 0)
```



`stripchart(varquant)` :
particulièrement adaptée pour une variable quantitative
discrète ou de mesure discrète


```
stripchart(d$AGE, method = "stack", pch = 19, at = 0)
```



sunflowerplot(varquant, varquant) : nuage de points avec tournesols


Visualisation des points superposés par des tournesols

```
sunflowerplot(POIDS ~ AGE, data = d)
```




`boxplot(varquant ~ varqual, notch = TRUE)` :
variante des diagrammes en boîtes avec intervalles de
confiance approché sur les médianes

`boxplot(POIDS ~ SEXE, data = d, notch = TRUE)`



stripchart(varquant ~ varqual) : report des points par groupe


```
stripchart(POIDS ~ SEXE, data = d, vertical = TRUE)
```



Problème : on ne distingue pas les ex-aequos


`stripchart(..., method = "jitter")` :
bruitage des abscisses et changement du type de points

```
stripchart(POIDS ~ SEXE, data = d, vertical = TRUE,  
           method = "jitter", pch = 19)
```




`stripchart(..., method = "stack")` :
empilement des points ex-aequos

```
stripchart(POIDS ~ SEXE, data = d, vertical = TRUE,  
           method = "stack", pch = 19)
```



`stripchart(..., method = "stack")` :
variante en écartant les points

```
stripchart(POIDS ~ SEXE, data = d, vertical = TRUE,  
           method = "stack", pch = 19, offset = 1)
```



Diagrammes en bâtons accolés (1)

```
# Calcul de la table de contingence  
(t <- table(d$SEXE, d$DECISION))
```


	av. 10 ans	10-15 ans	ap. 15 ans
F	31	23	15
M	19	8	11

```
# Calcul des fréquences sur chaque ligne  
(tf <- prop.table(t, margin = 1))
```

	av. 10 ans	10-15 ans	ap. 15 ans
F	0.449	0.333	0.217
M	0.500	0.211	0.289

Diagrammes en bâtons accolés (2)

```
barplot(tf, beside = TRUE, legend.text = TRUE)
```



Personnalisation des graphes en utilisant les arguments de fonctions graphiques

Il est très simple d'accéder à l'aide de chaque fonction **R** qui décrit en particulier tous les arguments de la fonction.

Exemples :


```
?barplot
```

```
?stripchart
```

```
?boxplot
```


Exemple de diagramme en bâtons utilisant les arguments de la fonction `barplot()`

```
barplot(tf, beside = TRUE, names.arg = c("avant 10 ans", "entre 10 et 15 ans", "après 15 ans"),  
        ylab = "fréquence", legend.text = TRUE,  
        xlab = "Moment auquel l'étudiant a décidé de devenir vétérinaire",  
        col = c("pink", "lightblue"))
```



Exemple de nuage de points avec points reliés utilisant la fonction `plot()`

```
plot(1:10, exp(1:10), type = "b", pch = 16, lty = 2, col = "red",  
     xlab = "x", ylab = "exp(x)", xlim = c(0,11))
```




Quelques arguments classiques à connaître

- `type` (type de tracé)
- `pch` (type de point)
- `lty` (type de ligne)
- `lwd` (largeur de la ligne)
- `cex` (de combien le texte et les symboles de tracé doivent être agrandis par rapport à la valeur par défaut)
- `col` (couleur)
- `xlim`, `ylim` (limites sur x et y)
- `xlab`, `ylab` (noms des axes)
- `main` (titre du graphe)

A vous de jouer !

Consigne

Pour vous familiarisez avec les fonctions graphiques et leurs arguments, tentez de reproduire le graphe suivant.




Autres fonctions

Afin de réaliser de belles figures publiables dans un article ou présentables dans un diaporama, quelques autres fonctionnalités graphiques de **R** sont à connaître :

- ajout d'un tracé (2^{ème} graphe) à un graphe existant
- ajout de texte à un graphe existant
- organisation des graphes sur une fenêtre
- divers paramètres d'une fenêtre graphique
- export d'une fenêtre graphique


Ajout d'une ligne : fonction `lines()`

```
hist(d$POIDS, freq = FALSE)  
lines(density(d$POIDS))
```



Ajout d'un texte : fonction `text()`


```
plot(POIDS ~ TAILLE, data = d, pch = 16)  
text(x = 160, y = 80, labels = "texte ajouté ici", col = "red")
```



On ajoute ainsi un texte à l'abscisse et l'ordonnée indiquées.

Utilisation du paramètre "usr" pour les variables qualitatives (coordonnées numériques des axes)


```
boxplot(POIDS ~ SEXE, data = d)  
par("usr")  
[1] 0.42 2.58 45.08 96.92  
text(x = 1, y = 90, labels = "texte ajouté ici", col = "red")
```



Ajout d'un texte dans la marge : fonction `mtext()`

```
plot(POIDS ~ TAILLE, data = d, pch=16)  
mtext(text = "texte ajouté ici", col = "red", side = 4, line = 0)  
mtext(text = "autre texte ajouté ici", col = "blue", side = 3, line = 2)
```


autre texte ajouté ici



On ajoute ainsi un texte dans la marge codée par `side` et la ligne codée par `line`.

Ajout d'une légende : fonction `legend()`

```
plot(POIDS ~ TAILLE, data = d, col = c("pink", "blue")[d$SEXE], pch = 16)  
legend(x = 155, y = 90, legend=c("F", "M"), col = c("pink", "blue"),  
      bty = "n", pch = 16)
```




Le premier argument `x` de la fonction `legend()` peut aussi être fixé à `"bottomleft"`, `"topright"`, `"center"`, ...

Ecriture mathématique dans un texte ajouté

Comme insérer symboles, exposants, indices dans une légende, une étiquette, un titre ?

```
plot(POIDS / TAILLE^2 ~ SEXE, data = d, xlab="sexe",  
     ylab = expression( paste( "IMC (kg.cm-2," )" )))
```



Codage des écritures mathématiques

Consigne

Explorez l'aide de `plotmath` et/ou tapez `demo(plotmath)`.

Autres ajouts


- ajout d'une flèche (fonction `arrows()`)
- ajout d'un segment (fonction `segments()`)
- ajout d'une ligne droite (fonction `abline()`)
- ajout d'un ou plusieurs points (fonction `points()`)
- ajout d'un axe (fonction `axis()`)

On peut aussi ajouter l'argument `add = TRUE` dans pas mal de fonctions graphiques (par exemple `hist()`, `stripchart()`, ...) pour faire un graphe par dessus un autre.


Consigne

En vous aidant de l'aide en ligne, tentez de refaire la figure de gauche, et si vous allez très vite celle de droite en prime

un graphique pour s'amuser !



A 2nd one for the fastest



Organisation de plusieurs graphes sur une même fenêtre

Avant le premier tracé, utilisation de l'une des deux fonctions suivantes :




- `par(mfrow=c(k,1))` avec `k` et `1` les nombres de lignes et de colonnes pour un découpage régulier de la fenêtre graphique en `k*1` cellules
- `layout(m)` pour un découpage régulier suivi d'un regroupement de certaines cellules, tel que spécifié dans la matrice `m`.

Ex. pour deux graphes de même largeur en haut et un 2 fois plus large en bas :

```
m <- matrix(c(1,2,3,3), nrow = 2, byrow = TRUE)
```



Exemple d'utilisation de par(mfrow)

```
par(mfrow=c(1,3))
hist(d[d$SEXE=="F",]$TAILLE, xlim = c(150,200), breaks = seq(150,200,2),
     xlab = "taille en cm", main = "")
hist(d[d$SEXE == "M",]$TAILLE, xlim = c(150,200), breaks = seq(150,200,2),
     xlab = "taille en cm", main = "")
plot(TAILLE ~ SEXE, data = d, xlab = "sexe", ylab = "taille en cm")
```



Exemple d'utilisation de la fonction layout()

```
m <- matrix(c(1,2,3,3), nrow = 2, byrow = TRUE)
layout(m)
hist(d[d$SEXE == "F",]$TAILLE, xlim = c(150,200), breaks = seq(150,200,2),
     xlab = "taille en cm", main = "")
hist(d[d$SEXE == "M",]$TAILLE, xlim = c(150,200), breaks = seq(150,200,2),
     xlab = "taille en cm", main = "")
plot(TAILLE ~ SEXE, data = d, xlab = "sexe", ylab = "taille en cm")
```



Modification des paramètres graphiques par défaut - marges

De nombreux paramètres graphiques sont récupérables ou modifiables à l'aide de la fonction `par()` à appliquer sur une fenêtre graphique ouverte, **mais avant d'y réaliser le tracé.**

Il est par exemple souvent utile de modifier les marges avant un découpage de fenêtre graphique.

Pour cela on utilise la commande

```
par(mar = c(bottom, left, top, right))
```

Les quatre valeurs données indiquent les largeurs des marges respectivement

en bas, à gauche, en haut et à droite,
et il faut savoir que par défaut elles sont à `c(5.1, 4.1, 4.1, 2.1)`.

Modification des paramètres graphiques par défaut - autres paramètres

Pour explorer quelques autres paramètres, faire :

```
?par
```


Ce serait trop long et complexe de tout explorer mais regardez-en voire testez en quelques-uns : `bg`, `bty`, `las`, `mar`, `mfrow`, `usr`, `xaxt`, `col` et `yaxt`, `xlog` et `ylog`.

Gestion des couleurs de base

- On peut coder les 8 couleurs de base par leur numéros.

```
par(mar = c(2, 0, 0, 0))
```

```
plot(rep(1,10), col = 1:10, pch = 19, cex = 5)
```




- Pour connaître toutes les couleurs disponibles par défaut on peut taper `colors()` et les voir à partir de <http://www.stat.columbia.edu/~tzheng/files/Rcolor.pdf>.

Création de palettes de couleur

Il est facile de créer des palettes de couleurs en définissant un nombre donné de couleurs dans une palette prédéfinie (par ex. avec `heat.colors()`, `terrain.colors()`, `topo.colors()`).

```
par(mar = c(2, 0, 0, 0))  
coul <- topo.colors(n = 10)  
plot(rep(1,10), col = coul[1:10], pch = 19, cex = 5)
```



Gestion de la transparence des couleurs (1)

- la fonction `col2rgb()` permet de récupérer le codage RGB d'une couleur :

```
(redinrgb <- col2rgb("red"))  
      [,1]  
red      255  
green     0  
blue      0
```

- la fonction `rgb()` permet de créer une couleur avec la transparence définie par l'argument `alpha` :

```
redT <- rgb(redinrgb[1], redinrgb[2], redinrgb[3],  
            maxColorValue = 255, alpha = 100)
```

Gestion de la transparence des couleurs plus simple mais nécessitant le package ggplot 2 (1 bis)

Même chose en une seule étape :

```
require(ggplot2)  
redT.bis <- alpha("red", alpha = 0.4)
```



Gestion de la transparence des couleurs (2)

Exemple d'utilisation de la couleur avec transparence

```
par(mfrow = c(1,2))
```

```
plot(d$TAILLE, d$POIDS, col = "red", pch = 16)
```


```
plot(d$TAILLE, d$POIDS, col = redT, pch = 16)
```



Exemple de figure utilisant la transparence

Consigne

En vous aidant de ce que l'on a vu, réalisez la figure suivante, en utilisant en particulier la transparence.



Exportation d'un graphique

Il existe une multitude de formats d'échange. Voici deux façons de procéder pour exporter une fenêtre graphique.

- 1 On ouvre une fenêtre graphique, on trace la figure, puis on l'exporte à l'aide de la fonction `dev.copy()` suivi de `dev.off()`.

```
plot(.....)
dev.copy(device = pdf, file = "joligraphe.pdf")
dev.off()
```

- 2 On ouvre directement le fichier dans lequel on veut exporter la figure, à l'aide de l'une des fonctions `jpeg()`, `pdf()`, ..., on trace la figure et on ferme le fichier avec la fonction `dev.off()`.


```
jpeg("toto.jpg", quality = 100, width = 15, height = 15,
     units = "cm", pointsize = 12, res = 300)
plot(.....)
dev.off()
```

Permet de gérer la taille, la résolution et la qualité de compression.

Réalisation et export d'une figure

Consigne

Réalisez la figure suivante (marges, couleur d'arrière plan, type de boîte de tracé, ...), puis exportez-la et insérez-la en bonne définition en jpeg dans un texte. Refaites la même chose en divisant par deux la hauteur et la longueur de la figure pour voir ce que cela donne.



Package ggplot2

Comment le package ggplot2 peut vous simplifier la vie dans certains cas ?

Introduction à l'utilisation du package ggplot2

Le package ggplot2 facilite grandement la visualisation par des couleurs, types de lignes ou de points, ..., d'autres variables que celles représentées en x et y .

Son utilisation requiert que les données soient correctement codées et toutes dans le même objet de type `data.frame`.

Pour faire des graphes très rapidement on peut utiliser la fonction `qplot()` (q pour “quick”) sans trop rentrer dans la grammaire des graphes implémentée dans `ggplot2` (gg pour “grammar of graphics”).

Utilisation de qplot()


Les divers arguments de qplot() :

- Premier argument : x
- Deuxième argument (optionnel) : y
- `data` : le jeu de données (tout doit y être)
- `geom` : le type de tracé ("point", "jitter", "line", "boxplot", "histogram", "density", ...)
- `colour`, `shape`, `size`, `group` : variables codant pour la couleur, le type de point, ..., ou juste pour séparer des groupes
- `facets` : une formule pour découper la figure suivant un ou deux facteurs : $\sim f1$ ou $f2 \sim f1$
- les arguments additionnels classiques : `main`, `xlim`, `ylim`, `xlab`, `ylab`, `log`, ...

Prenons quelques exemples en vrac pour explorer qplot().


Exemple de base avec x **quantitatif** et pas de y

```
require(ggplot2)  
qplot(TAILLE, data = d, geom = "density")
```




En dissociant les deux sexes

```
qplot(TAILLE, data = d, geom = "density", group = SEXE)
```




En associant une couleur par sexe

```
qplot(TAILLE, data = d, geom = "density", colour = SEXE)
```




En coloriant sous la courbe de densité

```
qplot(TAILLE, data = d, geom = "density", fill = SEXE)
```




En ajoutant un degré de transparence

```
qplot(TAILLE, data = d, geom = "density", fill = SEXE,  
      alpha = I(0.5))
```




Exemple de base avec x **qualitatif** et y **quantitatif**

```
qplot(CADRE, TAILLE, data = d, colour = SEXE)
```




En divisant la figure (une par sexe)

```
qplot(CADRE, TAILLE, data = d, colour = SEXE, facets = ~ SEXE)
```




Avec des diagrammes en boîte - version 1

```
qplot(CADRE, TAILLE, data = d, colour = SEXE, geom = "boxplot")
```




Avec des diagrammes en boîte - version 2

```
qplot(CADRE, TAILLE, data = d, fill = SEXE, geom = "boxplot")
```




Exemple de base avec x quantitatif et y quantitatif

```
qplot(TAILLE, POIDS, data = d, colour = SEXE)
```




En divisant par le cadre de vie

```
qplot(TAILLE, POIDS, data = d, colour = SEXE, facets = ~ CADRE)
```




Avec l'âge codant pour la taille des points

```
qplot(TAILLE, POIDS, data = d, colour = SEXE, size = AGE,  
      alpha = I(0.5))
```




En séparant les figures par sexe et cadre de vie, avec l'âge codant pour la couleur

```
qplot(TAILLE, POIDS, data = d, facets = CADRE ~ SEXE, colour = AGE)
```



En contours de la densité de probabilité

```
qplot(TAILLE, POIDS, data = d, facets = CADRE ~ SEXE,  
      colour = SEXE, geom = "density2d")
```



Application à un exemple classique de **données** longitudinales

Suivi au cours du temps du poids de souris appartenant à deux groupes

```
dlong <- read.table("DATA/tramadol_poids.txt", header = TRUE,  
                    dec = ",", stringsAsFactors = TRUE)
```

```
str(dlong)
```

```
'data.frame':      192 obs. of  4 variables:
```

```
$ souris      : Factor w/ 24 levels "B","BB","BBR",...: 1 14 21 6 24 2 22
```

```
$ jour        : int   1 1 1 1 1 1 1 1 1 1 ...
```

```
$ traitement: Factor w/ 2 levels "serum","tramadol": 2 2 2 2 2 2 2 2 2 1
```


```
$ poids       : num   19.2 17.8 19.2 18.4 18.6 19 19.5 18.5 18.5 18.2 ...
```

Consigne

Proposez diverses façons de représenter les cinétiques de poids individuelles à l'aide de la fonction `qplot()`.


Ajout des courbes moyennes (version 1)

```
qplot(jour, poids, data = dlong, geom = c("line", "point"),  
      facets = ~ traitement, group = souris) +  
stat_summary(aes(group = traitement), fun.y = mean,  
            geom = "line", lwd = 2)
```



Ajout des courbes moyennes (version 2)

```
qplot(jour, poids, data = dlong, geom = "line",  
      colour = traitement, group = souris) +  
stat_summary(aes(group = traitement), fun.y = mean,  
            geom = "line", lwd = 2)
```



Construction du graphe avec ggplot()

Pour aller plus loin dans l'utilisation du package ggplot2 il faut comprendre la **grammaire des graphes** implémentée.

- 1 Le graphe est un objet **R** défini tout d'abord par un jeu de données et une esthétique (`aes()` : `x`, `y`, codage de couleur, de forme, de groupe, ...).

```
g <- ggplot(data = dlong, mapping = aes(x = jour,  
                                         y = poids, group = souris, colour = traitement))
```

- 2 Le graphe est ensuite représenté avec une ou plusieurs géométries (fonctions `geom_point()`, `geom_line()`, `geom_boxplot()`, `geom_density()`, ...) et un éventuel découpage (fonctions `facet_wrap()` en 1D ou `facet_grid()` en 2D).

```
g + geom_line() + geom_point() +  
  facet_wrap("traitement")
```


Comparaison des écritures avec qplot() et ggplot()

Avec qplot()

```
qplot(jour, poids, data = dlong, geom = c("point", "line"),
      colour = traitement, group = souris)
```

Avec ggplot()

```
g <- ggplot(data = dlong, mapping = aes(x = jour,
      y = poids, group = souris, colour = traitement))
g + geom_line() + geom_point() +
  facet_wrap("traitement")
```




Personnalisation des graphes avec ggplot2

La personnalisation des graphes réalisés avec la fonction `qplot()` est limitée.

L'utilisation de la fonction `ggplot()` puis des fonctions de géométrie (fonctions `geom_point()`, `geom_line()`, `geom_boxplot()`, `geom_density()`, ...) permet de personnaliser les graphes en spécifiant les arguments de ces fonctions.

Reprenons la représentation de la taille en points


```
qplot(CADRE, TAILLE, data = d, colour = SEXE)
```



On se doute qu'il y a des ex-aequos qu'on va faire apparaître avec la géométrie "jitter".

Reprenons la représentation de la taille en fonction du sexe


```
qplot(CADRE, TAILLE, data = d, colour = SEXE, geom = "jitter")
```



Bruitage un peu large et à la fois sur les x et les y. Comment le personnaliser ?


Par utilisation explicite de geom_jitter()

```
ggplot(data = d, aes(x = CADRE, y = TAILLE, colour = SEXE)) +  
  geom_jitter(height = 0, width = 0.2)
```



Personnalisation par utilisation de fonctions complémentaires

```
ggplot(data = d, aes(x = CADRE, y = TAILLE, colour = SEXE)) +  
  geom_jitter(height = 0, width = 0.2) + theme_bw() +  
  ggtitle("Taille des étudiants vétérinaires") + xlab("cadre de vie")
```



Pour aller plus loin ...

La fonction `qplot()` (“quick plot”) du package `ggplot2` offre la possibilité de générer très facilement de multiples graphes complexes.

Pour les personnaliser ou créer des graphes plus sophistiqués on peut utiliser la fonction `ggplot()` et les multiples fonctions du package dont je ne vous ai montré qu’une infime partie. Cela nécessite un peu plus d’investissement mais de nombreuses informations sont disponibles en ligne :

<http://www.statmethods.net/advgraphs/ggplot2.html>

<http://www.cookbook-r.com/Graphs/>

Très utile, l’antisèche de `ggplot2` :

<https://www.rstudio.com/wp-content/uploads/2016/11/ggplot2-cheatsheet-2.1.pdf>

Le package esquisse pour vous aider à démarrer un nouveau graphe

Le package à installer :

https:

[//cran.r-project.org/web/packages/esquisse/index.html](https://cran.r-project.org/web/packages/esquisse/index.html)

Sa vignette :

<https://cran.r-project.org/web/packages/esquisse/vignettes/get-started.html>

Essayez-le rapidement sur un exemple de graphe à partir de l'objet R de type data.frame dans lequel vous avez importé les données de "ENQ9697.txt" par exemple.

Quand utiliser graphics ou ggplot2 ?

- ggplot2 permet de réaliser en un nombre réduit de lignes de code des graphes permettant de visualiser l'effet de nombreux facteurs.
- ggplot2 gère automatiquement les légendes mais avec des choix par défaut (couleurs, types de points ...) qui sont un peu plus difficiles à modifier qu'avec graphics.
- Lorsque l'on veut réaliser un graphe très spécifique et très personnalisé il reste parfois plus simple de le réaliser avec graphics.

Les deux packages restent semble-t-il donc complémentaires !

L'utilisation de fonctions peut être utile pour personnaliser un graphe

Pour vous vous montrer un exemple simple prenons le jeu de données suivant sur lequel nous allons, pour chaque vache, calculer son GMQ par régression linéaire, et le reporter sur chaque graphe de régression.

```
dGMQ <- read.table("DATA/GMQ_6vaches.txt",  
                    header = TRUE, stringsAsFactors = TRUE)  
str(dGMQ)
```

```
'data.frame':      42 obs. of  3 variables:  
 $ nom      : Factor w/ 6 levels "Betty","Blondie",...: 4 4  
 $ age_jours: int   182 212 243 273 304 334 365 182 212 243  
 $ poids_kg : int   134 155 177 187 201 215 232 156 159 172
```


Comment écrire une fonction

Principe de codage d'une fonction **R**

```
nomdelafunction <- function(argument1, argument2, ...)  
{  
  instruction1  
  instruction2  
  ...  
  # si on veut sortir un objet qui n'est pas celui  
  # défini dans la dernière instruction  
  return(sortie)  
}
```


Exemple de fonction

Fonction qui, pour un sous-jeu de données `d1vache` correspondant à une vache, fait la régression et trace le graphe souhaité, en y reportant le GMQ

```
GMQ <- function(d1vache)
{
  reg <- lm(poids_kg ~ age_jours, data = d1vache)
  nomvache <- d1vache$nom[1]
  plot(poids_kg ~ age_jours, data = d1vache, pch = 16, n
        ylim = c(140, 250))
  abline(reg, col = "blue")
  gmq <- round(coef(reg)[2], 3)
  text(250, 230, paste("GMQ = ", gmq, " kg/jr"))
  return(gmq)
}
```


Exemple d'application de la fonction à une vache

```
dBetty <- subset(dGMQ, nom == "Betty")  
GMQ(dBetty)
```




Rappel du principe de la fonction `tapply`

`tapply(vecteur, facteur, fonction)`



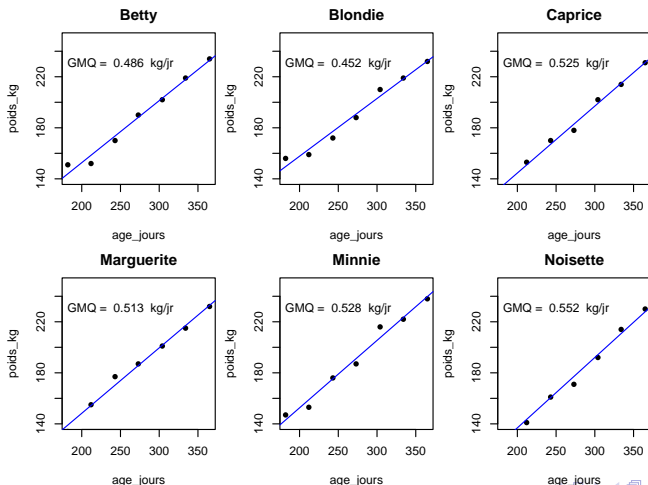
Principe de la fonction `by`

`by(tableau_de_donnees, facteur, fonction)`



Application de la fonction à toutes les vaches à l'aide de `by`

```
par(mfrow = c(2,3), mar = c(4, 4, 2.5, 0.5))  
by(dGMQ, dGMQ$nom, GMQ)
```



Comment faire lorsqu'on part d'un jeu de données au format large ?

Prenons un exemple.

```
dlarge <- read.table("DATA/tableau_kappa.txt", header = TRUE,  
                     stringsAsFactors = TRUE)
```

```
str(dlarge)
```

```
'data.frame':      4 obs. of  9 variables:  
 $ observateur   : int   1 2 3 4  
 $ photo_dos     : num   0.84 0.68 0.85 0.67  
 $ photo_aplombs : num   0.65 0.57 0.77 0.72  
 $ photo_score   : num   0.83 0.59 0.8 0.7  
 $ photo_statut  : num   0.84 0.67 0.83 0.67  
 $ visu_dos      : num   0.49 0.54 0.54 0.53  
 $ visu_aplombs  : num   0.53 0.25 0.37 0.53  
 $ visu_score    : num   0.51 0.45 0.23 0.41  
 $ visu_statut   : num   0.49 0.47 0.2 0.46
```

Utilité de la fonction `stack()` pour passer du format large au format long

```
dlong <- stack(dlarge[, -1])  
str(dlong)
```

```
'data.frame':      32 obs. of  2 variables:  
 $ values: num  0.84 0.68 0.85 0.67 0.65 0.57 0.77 0.72 0.83 0.59 ...  
 $ ind : Factor w/ 8 levels "photo_dos","photo_aplombs",...: 1 1 1 1 2  
head(dlong)
```

	values	ind
1	0.84	photo_dos
2	0.68	photo_dos
3	0.85	photo_dos
4	0.67	photo_dos
5	0.65	photo_aplombs
6	0.57	photo_aplombs

Manipulations complémentaires pour créer les variables utiles (1)

```
# changement de nom de la variable d'intérêt
# (ici coefficient kappa de concordance)
colnames(dlong)[1] <- "kappa"
# création du facteur 'observateur'
dlong$observateur <- factor(rep(dlarge$observateur,
                                ncol(dlarge) - 1))

str(dlong)

'data.frame':      32 obs. of  3 variables:
 $ kappa          : num  0.84 0.68 0.85 0.67 0.65 0.57 0.77 0.72 0.83 0.59
 $ ind            : Factor w/ 8 levels "photo_dos","photo_aplombs",...: 1 1
 $ observateur: Factor w/ 4 levels "1","2","3","4": 1 2 3 4 1 2 3 4 1 2
```

Manipulations complémentaires pour créer les variables utiles (1)

```
levels(dlong$ind)


[1] "photo_dos"      "photo_aplombs" "photo_score"    "photo_statut"
[5] "visu_dos"       "visu_aplombs"  "visu_score"     "visu_statut"

# création du facteur indiquant sur quelle mesure
# la concordance a été évaluée
dlong$variable <- dlong$ind
levels(dlong$variable) <- c("dos", "aplombs", "score",
                           "statut", "dos", "aplombs",
                           "score", "statut")

# création du facteur indiquant les conditions de la mesure
dlong$condition <- dlong$ind
levels(dlong$condition) <- c("photo", "photo", "photo",
                             "photo", "visu", "visu",
                             "visu", "visu")
```

Il n'y a plus qu'à utiliser `ggplot()` sur ce nouveau jeu de données reformaté

```
ggplot(dlong, aes(x = variable, y = kappa, colour = observateur,
  group = observateur:condition)) +
  geom_line() + geom_point() + facet_wrap(~ condition)
```



A vous de jouer !

Consigne

Prenez vos propres jeux de données et tentez de créer des graphes intéressants (avec ou sans ggplot2, avec ou sans fonctions).
N'oubliez pas de vérifier en préliminaire le bon codage de vos données.

Un exemple à reproduire pour ceux qui n'ont pas de données :

Taille des étudiants vétérinaires

